

# Машинное обучение: линейные модели классификации и регрессии

Эмели Драль  
СВР, Москва 2020

# Программа курса

Курс состоит из **5ти** блоков:

1. **Базовые** концепции машинного обучения
2. **Линейные** модели классификации и регрессии
3. **Деревья решений** в классификации и регрессии, ансамбли моделей
4. Обучение **без учителя** и частичное обучение
5. **Нейронные сети** и глубокое обучение, backpropagation, регуляризация и методы оптимизации

# План занятия

1. Обзор алгоритмов обучения с учителем
2. Линейные модели: интуиция
3. Линейные модели: построение
4. Обзор метрик качества (если успеем)

# Обзор алгоритмов обучения с учителем

# Обучение с учителем

## Базовые концепты

Объекты и признаки:

- $x$  – объект
- $y$  – ответ
- $(f_1, f_2 \dots f_n)$  – признаки,
- описывающие объекты

Модель:

- $a: X \rightarrow Y$
- $a(x) = y$
- $A$  – семейство моделей

- $X$  – пространство объектов
- $Y$  – пространство ответов

Оценка качества

- $Q(a, X)$  – ошибки модели  $a(x)$  на группе объектов  $X$

## Обучение с учителем

### Как построить модель?

1. Подготовить набор данных  $X = (x_i, y_i)_{i=1, l}$
2. Выбрать семейство алгоритмов  $A$
3. Минимизировать ошибки модели  $Q(a, X) \rightarrow$   
за счет этого получить конкретную модель  
 $a(x)$  из выбранного семейства  $A$

Обучение с  
учителем

? Какие идеи заложены в модели?

Обучение с  
учителем

## Семейства алгоритмов

- Метод ближайших соседей
  - Линейные модели
  - Деревья решений
  - Ансамбли
  - Нейронные сети
- и др.



## Обучение с учителем

# Семейства алгоритмов

- Метод ближайших соседей: похожие объекты относятся к одному классу
- Линейные модели
- Деревья решений
- Ансамбли
- Нейронные сети
- и др.

# Метод ближайших соседей

Обучение с учителем



F



M



M

Обучение с  
учителем

# Метод ближайших соседей



F



?




M



M


# Метод ближайших соседей

Обучение с учителем



# Метод ближайших соседей

Обучение с учителем



Обучение с  
учителем

# Метод ближайших соседей



# Метод ближайших соседей

Обучение с учителем



## Обучение с учителем

# Семейства алгоритмов

- Метод ближайших соседей: похожие объекты относятся к одному классу
- Линейные модели: класс линейно зависит от характеристик объекта
- Деревья решений
- Ансамбли
- Нейронные сети
- и др.



Обучение с  
учителем

# Линейная модель



Стоит ли одобрить кредит данному клиенту?

Обучение с  
учителем

# Линейная модель



Стоит ли одобрить кредит данному клиенту?



# Линейная модель



Стоит ли одобрить кредит данному клиенту?



15



99



35

Обучение с  
учителем

# Линейная модель



Стоит ли одобрить кредит данному клиенту?



15

+



99

+



35

Обучение с  
учителем

## Обучение с учителем

# Семейства алгоритмов

- Метод ближайших соседей: похожие объекты относятся к одному классу
- Линейные модели: класс линейно зависит от характеристик объекта
- Деревья решений: класс получается в результате последовательных ответов на простые вопросы
- Ансамбли
- Нейронные сети
- и др.

Обучение с  
учителем

# Дерево решений




Уйдет ли этот клиент к конкуренту?

# Дерево решений



Уйдет ли этот клиент к конкуренту?

Обучение с учителем

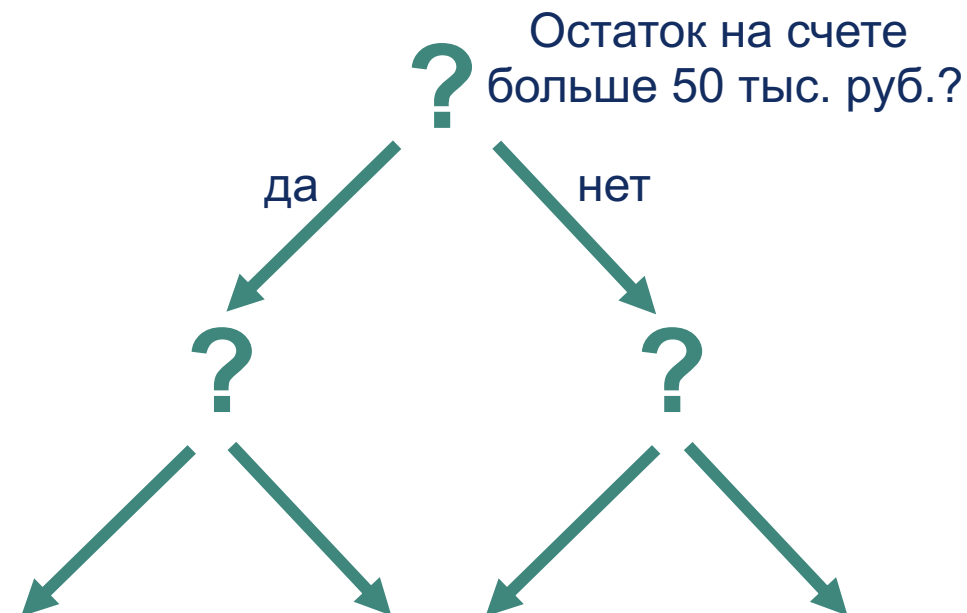


# Обучение с учителем

## Дерево решений



Уйдет ли этот клиент к конкуренту?

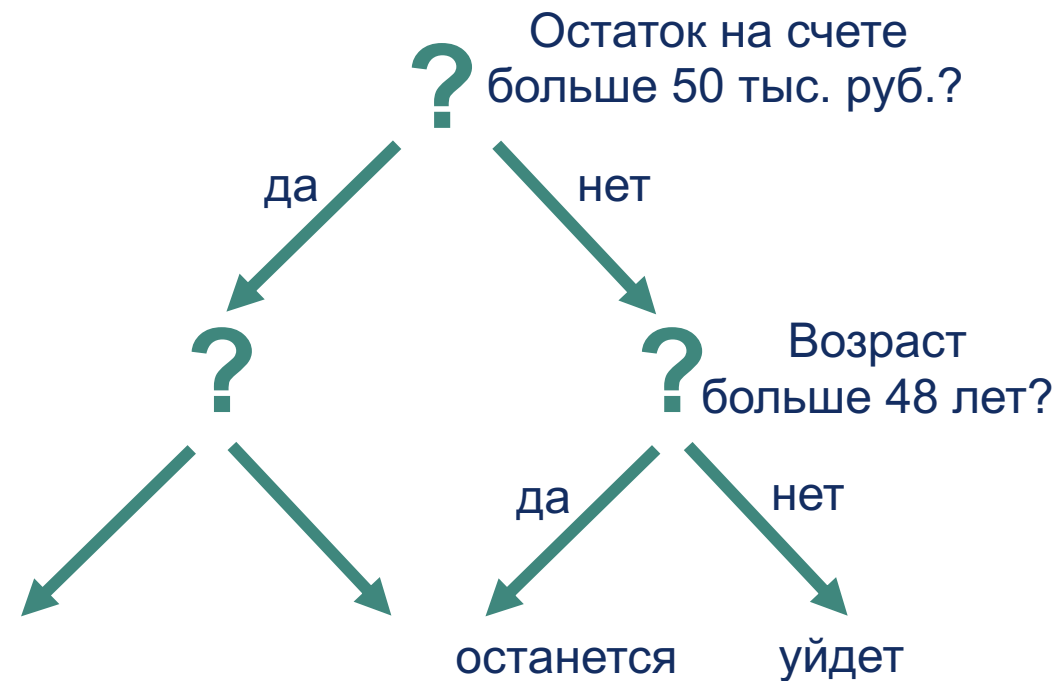




# Дерево решений



Уйдет ли этот клиент к конкуренту?

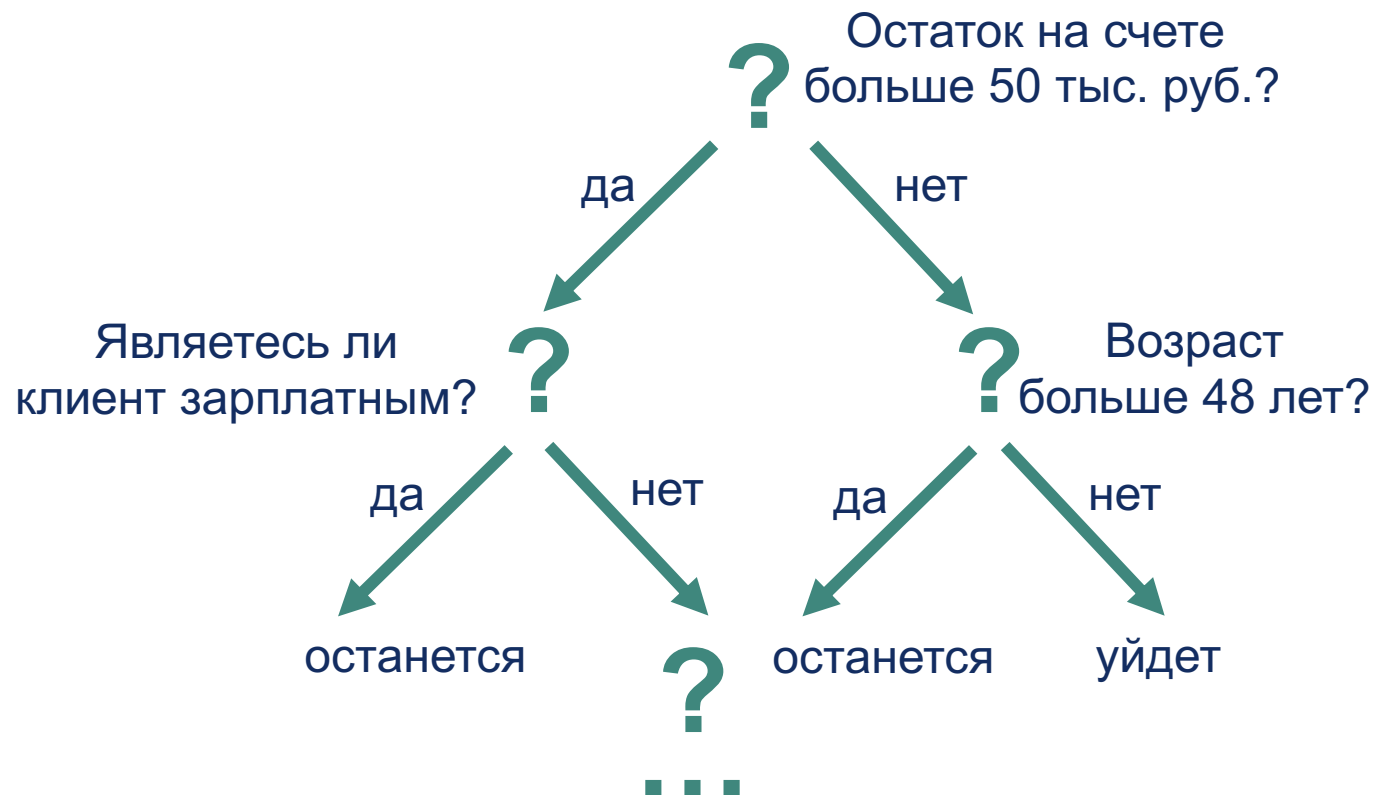


# Обучение с учителем

## Дерево решений



Уйдет ли этот клиент к конкуренту?



## Обучение с учителем

# Семейства алгоритмов

- Метод ближайших соседей: похожие объекты относятся к одному классу
- Линейные модели: класс линейно зависит от характеристик объекта
- Деревья решений: класс получается в результате последовательных ответов на простые вопросы
- Ансамбли: решение принимается на основе ответов нескольких моделей
- Нейронные сети
- и др.

Обучение с  
учителем

# Ансамбли




Уйдет ли этот клиент к конкуренту?

# Ансамбли

Обучение с учителем



Уйдет ли этот клиент к конкуренту?



Останется!



# Ансамбли

Обучение с учителем



Уйдет ли этот клиент к конкуренту?



# Ансамбли

Обучение с учителем



Уйдет ли этот клиент к конкуренту?



2 vs 1



## Обучение с учителем

# Семейства алгоритмов

- Метод ближайших соседей: похожие объекты относятся к одному классу
  - Линейные модели: класс линейно зависит от характеристик объекта
  - Деревья решений: класс получается в результате последовательных ответов на простые вопросы
  - Ансамбли: решение принимается на основе ответов нескольких моделей
  - Нейронные сети: нелинейная комбинация линейных моделей
- и др.

# Нейронные сети


Обучение с  
учителем



Стоит ли одобрить  
Кредит клиенту?

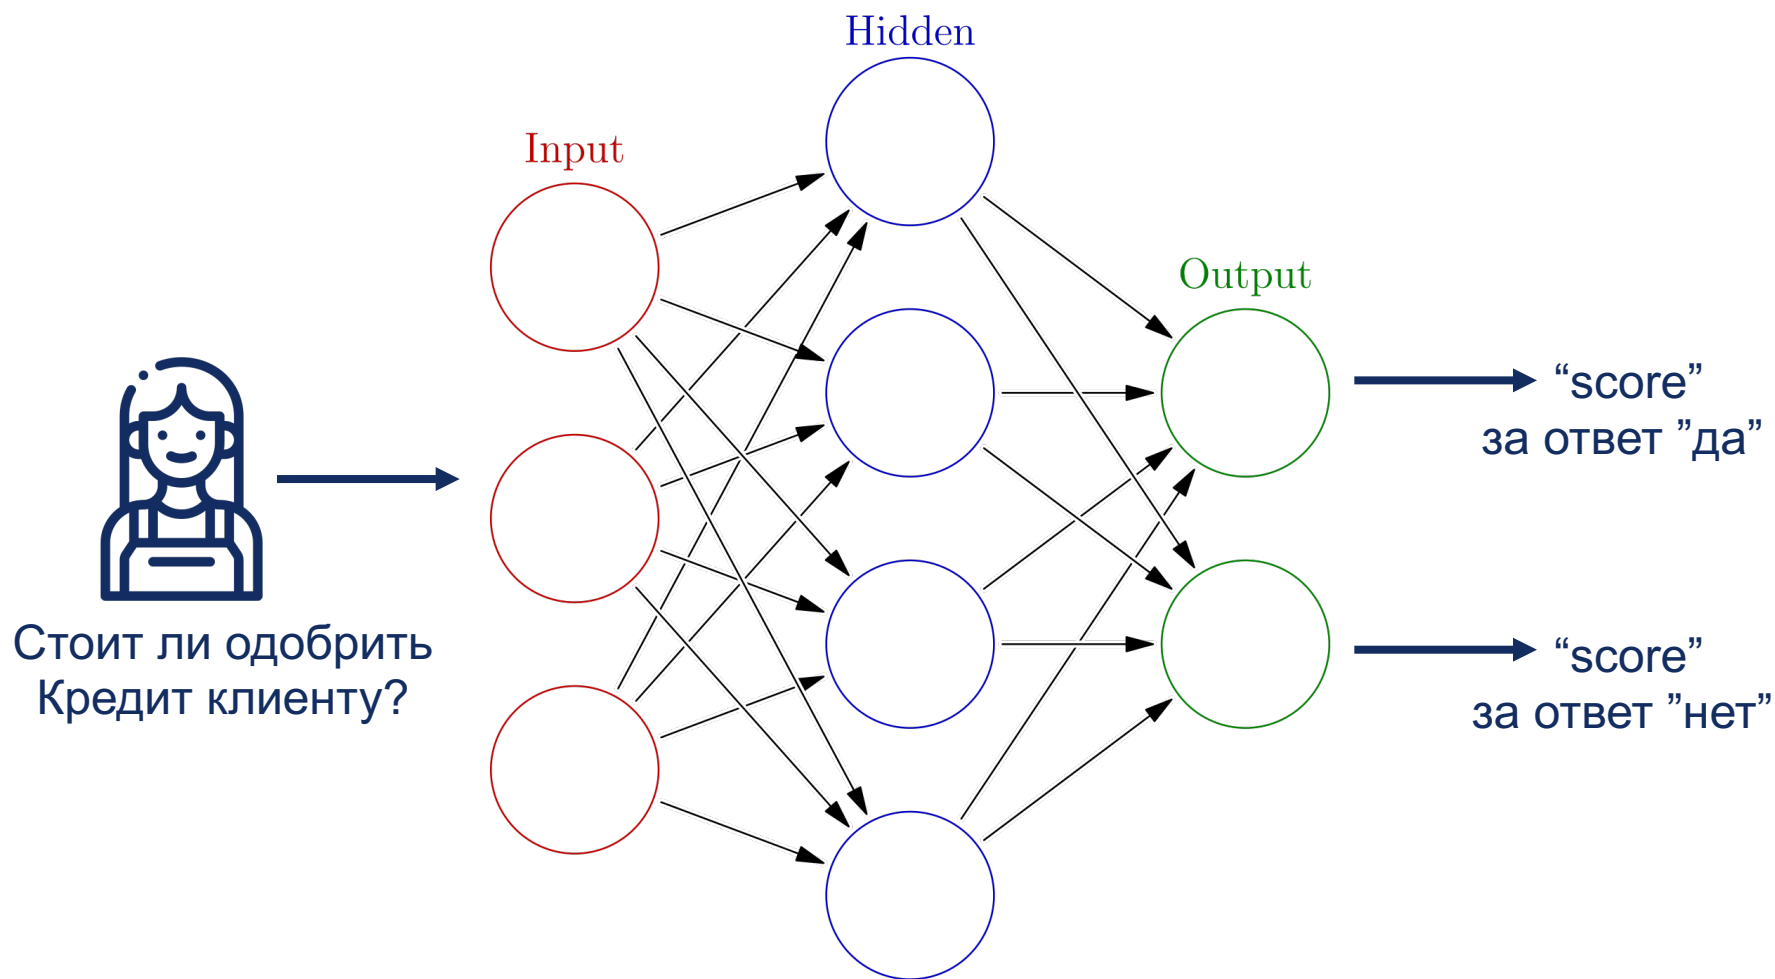
# Нейронные сети

Обучение с учителем



# Нейронные сети

Обучение с учителем



# Линейные модели: построение

## To take away:

- Алгоритмов очень много, области применения сильно различаются
- Все алгоритмы основаны на принципах базовой логики и математике
- Практически для всех алгоритмов есть готовая реализация (часто таких реализаций много), этим нужно пользоваться!

# Линейные модели: интуиция

Линейные  
модели:  
интуиция

? Давайте обучим модель?

Пример:  
занимать ли  
очередь в  
банке?

## Признаки (1/0)



Вы свободны в  
данный момент



Вы голодны



Вам хочется спать



В очереди меньше 3х  
человек



Пример:  
занимать ли  
очередь в  
банке?

## Признаки (1/0)



Вы свободны в  
данный момент



Вы голодны



Вам хочется спать



В очереди меньше 3х  
человек

Пример:  
занимать ли  
очередь в  
банке?


## Признаки (1/0)



Вы свободны в  
данный момент



Вам хочется спать



Вы голодны




В очереди меньше 3х  
человек

Пример:  
занимать ли  
очередь в  
банке?

## Признаки (1/0)



Вы свободны в  
данный момент



Вы голодны



Вам хочется спать




В очереди меньше 3х  
человек

Пример:  
занимать ли  
очередь в  
банке?

## Признаки (1/0)



Вы свободны в  
данный момент



Вы голодны



Вам хочется спать



В очереди меньше 3х  
человек

# Линейные модели

Пример:  
занимать ли  
очередь в  
банке?



Порог для решающего правила: 0  
Если сумма больше 0 – занимаем очередь!


# Линейные модели: интуиция

## Линейные модели

$$a(x) = \begin{cases} 1, & \text{если } f(x) \geq 0 \\ -1, & \text{если } f(x) < 0 \end{cases}$$

$$f(x) = w_0 + w_1x_1 + \dots + w_nx_n$$

Геометрическая  
интерпретация: разделяем  
классы плоскостью



Пример:  
скоринговые  
карты

| Показатель                | Диапазон значений   |
|---------------------------|---------------------|
| Возраст заёмщика          | До 35 лет           |
|                           | От 35 до 45 лет     |
|                           | От 45 и старше      |
| Образование               | Высшее              |
|                           | Среднее специальное |
|                           | Среднее             |
| Состоит ли в браке        | Да                  |
|                           | Нет                 |
| Наличие кредита в прошлом | Да                  |
|                           | Нет                 |
| Стаж работы               | До 1 года           |
|                           | От 1 до 3 лет       |
|                           | От 3 до 6 лет       |
|                           | Свыше 6 лет         |
| Наличие автомобиля        | Да                  |
|                           | Нет                 |

Пример:  
скоринговые  
карты

| Показатель                | Диапазон значений   | Скоринг-балл |
|---------------------------|---------------------|--------------|
| Возраст заёмщика          | До 35 лет           | 7,60         |
|                           | От 35 до 45 лет     | 29,68        |
|                           | От 45 и старше      | 15,87        |
| Образование               | Высшее              | 29,82        |
|                           | Среднее специальное | 20,85        |
|                           | Среднее             | 22,71        |
| Состоит ли в браке        | Да                  | 29,46        |
|                           | Нет                 | 9,38         |
| Наличие кредита в прошлом | Да                  | 40,55        |
|                           | Нет                 | 13,91        |
| Стаж работы               | До 1 года           | 15,00        |
|                           | От 1 до 3 лет       | 18,14        |
|                           | От 3 до 6 лет       | 19,85        |
|                           | Свыше 6 лет         | 23,74        |
| Наличие автомобиля        | Да                  | 51,69        |
|                           | Нет                 | 15,93        |



Пример:  
скоринговые  
карты

## Почему нельзя продолжать так же?

- Сложно настраивать вручную
- Требуется эксперт в области
- Требуется проверка на данных и уточнение весов (эксперт может что-то не учесть)

## Пример: скоринговые карты

# Почему нельзя продолжать так же?

- Сложно настраивать вручную
- Требуется эксперт в области
- Требуется проверка на данных и уточнение весов (эксперт может что-то не учесть)

## Решение

Автоматизируем подбор параметров:  
придумаем функцию от параметров, которую  
надо минимизировать, и используем методы  
численной оптимизации

## Пример: скоринговые карты

# Почему нельзя продолжать так же?

- Сложно настраивать вручную
- Требуется эксперт в области
- Требуется проверка на данных и уточнение весов (эксперт может что-то не учесть)

## Решение

Автоматизируем подбор параметров:  
придумаем функцию от параметров –  $Q(a)$ ,  
которую надо минимизировать  $Q(a) \rightarrow \min$ , и  
используем методы численной оптимизации

# Линейные модели: построение

Линейные  
модели:  
построение

# Линейная регрессия

$$a(x) = \langle w, x \rangle + w_0$$

# Линейные модели: построение

## Линейная регрессия

$$a(x) = \langle w, x \rangle + w_0$$

А как получить ответ в задаче классификации?

## Линейные модели: построение

# Линейная классификация

$$a(x) = \langle w, x \rangle + w_0$$

А как получить ответ в задаче классификации?

$$a(x) = \textit{sign}(\langle w, x \rangle + w_0)$$

Если скалярное произведение неотрицательное – класс 1, в противном случае класс 0

# Линейные модели: построение

## Линейная модель

$$a(x) = \langle w, x \rangle + w_0$$

$$a(x) = \textit{sign}(\langle w, x \rangle + w_0)$$

Вид модели задан. Теперь нужно выписать задачу оптимизации для настройки параметров модели (весов).



# Линейные модели: построение

## Отступ

Отступом алгоритма  $a(x) = \text{sign}\{f(x)\}$  на объекте  $x_i$  называется величина

$$M_i = y_i f(x_i)$$

( $y_i$  - класс, к которому относится  $x_i$ )

$$M_i \leq 0 \Leftrightarrow y_i \neq a(x_i)$$

$$M_i > 0 \Leftrightarrow y_i = a(x_i)$$

Линейные  
модели:  
построение

# Эмпирический риск

$$Q(w) = \sum_{i=1}^{\ell} [M_i(w) < 0]$$

# Линейные модели: построение

## Функция потерь

$$Q(w) = \sum_{i=1}^{\ell} [M_i(w) < 0] \leq \tilde{Q}(w) = \sum_{i=1}^{\ell} \mathcal{L}(M_i(w)) \rightarrow \min_w;$$

Функция эмпирического  
риска



Функция потерь



# Линейные модели: построение

## Функция потерь

$$Q(w) = \sum_{i=1}^{\ell} [M_i(w) < 0] \leq \tilde{Q}(w) = \sum_{i=1}^{\ell} \mathcal{L}(M_i(w)) \rightarrow \min_w;$$

Общий вид задачи оптимизации задан, остается несколько степеней свободы:


- функция потерь ( $L$ )
- дополнительные ограничения
- метод оптимизации

Давайте обсудим варианты.

# Функция потерь

$$Q(w) = \sum_{i=1}^{\ell} [M_i(w) < 0] \leq \tilde{Q}(w) = \sum_{i=1}^{\ell} \mathcal{L}(M_i(w)) \rightarrow \min_w;$$

Линейные  
модели:  
построение



$$\begin{aligned} Q(M) &= (1 - M)^2 \\ V(M) &= (1 - M)_+ \\ S(M) &= 2(1 + e^M)^{-1} \\ L(M) &= \log_2(1 + e^{-M}) \\ E(M) &= e^{-M} \end{aligned}$$

Линейные  
модели:  
построение

## Задача оптимизации

$$a(x) = \langle w, x \rangle + w_0$$

$$Q = \sum_{i=1}^l L(y_i, a(x_i)) \rightarrow \min_w$$

# Задача оптимизации

Линейные  
модели:  
построение

$$a(x) = \langle w, x \rangle + w_0$$

$$Q = \sum_{i=1}^l L(y_i, a(x_i)) \rightarrow \min_w$$

$$L(y_i, a(x_i)) = (y_i - a(x_i))^2 \qquad L(y_i, a(x_i)) = |y_i - a(x_i)|$$

# Задача оптимизации

Линейные  
модели:  
построение

$$a(x) = \langle w, x \rangle + w_0$$

$$Q = \sum_{i=1}^l L(y_i, a(x_i)) \rightarrow \min_w$$

$$L(y_i, a(x_i)) = (y_i - a(x_i))^2$$

$$V(w) = \|w\|_{l_2}^2 = \sum_{n=1}^d w_n^2$$

$$L(y_i, a(x_i)) = |y_i - a(x_i)|$$

$$V(w) = \|w\|_{l_1} = \sum_{n=1}^d |w_n|$$



Линейные  
модели:  
построение

# Задача оптимизации

$$a(x) = \langle w, x \rangle + w_0$$

$$Q = \sum_{i=1}^l L(y_i, a(x_i)) + \gamma V(w) \rightarrow \min_w$$

Гребневая регрессия  
(Ridge regression):

$$V(w) = \|w\|_{l_2}^2 = \sum_{n=1}^d w_n^2$$

LASSO (least absolute  
shrinkage and selection  
operator):

$$V(w) = \|w\|_{l_1} = \sum_{n=1}^d |w_n|$$

# Задача оптимизации

Линейные  
модели:  
построение

$$a(x) = \langle w, x \rangle + w_0$$

$$Q = \sum_{i=1}^l L(y_i, a(x_i)) \rightarrow \min_w$$

$$L(y_i, a(x_i)) = (y_i - a(x_i))^2$$

А без регуляризатора и с квадратичными потерями получаем привычную нам линейную регрессию

# Конструирование линейных моделей

## Линейные модели: построение

| Классификатор  | Функция потерь                        | Регуляризатор  |
|--|---------------------------------------|--|
| SVM (Support vector machine, метод опорных векторов) | $L(M) = \max\{0, 1 - M\} = (1 - M)_+$ | $\sum_{k=1}^m w_k^2$                                 |
| Логистическая регрессия                              | $L(M) = \log(1 + e^{-M})$             | Обычно $\sum_{k=1}^m w_k^2$ или $\sum_{k=1}^m  w_k $ |

# Решение задачи оптимизации

$$\text{Модель: } y_i \approx \hat{y}_i = \langle w, x_i \rangle + w_0$$

Линейные  
модели:  
построение

# Решение задачи оптимизации

Модель:  $y_i \approx \hat{y}_i = \langle w, x_i \rangle + w_0$

Если добавить  $x_{i0} = 1$ :

Линейные  
модели:  
построение

# Решение задачи оптимизации

Модель:  $y_i \approx \hat{y}_i = \langle w, x_i \rangle + w_0$

Если добавить  $x_{i0} = 1$ :

$$y_i \approx \hat{y}_i = \langle w, x_i \rangle$$

Линейные  
модели:  
построение

# Решение задачи оптимизации

## Линейные модели: построение

Модель:  $y_i \approx \hat{y}_i = \langle w, x_i \rangle + w_0$

Если добавить  $x_{i0} = 1$ :

$$y_i \approx \hat{y}_i = \langle w, x_i \rangle$$

$$y_1 \approx \hat{y}_1 = x_1^T w$$

...

$$y_i \approx \hat{y}_i = x_i^T w$$

...

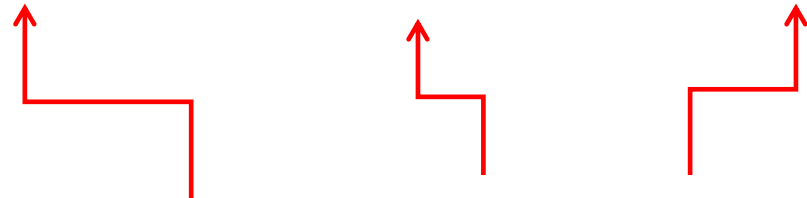
$$y_l \approx \hat{y}_l = x_l^T w$$

Линейные  
модели:  
построение

# Решение задачи оптимизации

Матричная запись

$$\begin{pmatrix} y_1 \\ y_2 \\ \dots \\ y_l \end{pmatrix} \approx \begin{pmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \dots \\ \hat{y}_l \end{pmatrix} = \begin{pmatrix} x_1^T \\ x_2^T \\ \dots \\ x_l^T \end{pmatrix} w$$


$$y \approx \hat{y} = Fw$$

$$w = \underset{w}{\operatorname{argmin}} \|y - \hat{y}\|^2$$



Линейные  
модели:  
построение

# Решение задачи оптимизации

$$\frac{\partial (Fw - y)^2}{\partial w} = 2F^T (Fw - y) = 0$$

$$F^T Fw = F^T y$$

$$w = (F^T F)^{-1} F^T y$$

Линейные  
модели:  
построение

# Решение задачи оптимизации

Если добавить  $\ell_2$  регуляризацию

$$\frac{\partial (Fw - y)^2 + \gamma w^2}{\partial w} = 2F^T(Fw - y) + 2\gamma w = 0$$

$$(F^T F + \gamma I)w = F^T y$$


$$w = (F^T F + \gamma I)^{-1} F^T y$$

# Линейные модели: построение

## Решение задачи оптимизации

Численное решение возможно с помощью  
градиентного спуска (GD, Gradient Decent)

$$x_{k+1} = x_k - \gamma_k \nabla F(x_k)$$




Линейные  
модели:  
построение

# Градиентный спуск (GD)

$$\nabla_w \tilde{Q} = \sum_{i=1}^l \nabla L(M_i) = \sum_{i=1}^l L'(M_i) \frac{\partial M_i}{\partial w}$$

$$x_{k+1} = x_k - \gamma_k \nabla F(x_k)$$




# Линейные модели: построение

## Градиентный спуск (GD)

$$\nabla_w \tilde{Q} = \sum_{i=1}^l \nabla L(M_i) = \sum_{i=1}^l L'(M_i) \frac{\partial M_i}{\partial w}$$

$$x_{k+1} = x_k - \gamma_k \nabla F(x_k)$$

$$M_i = y_i \langle w, x_i \rangle \Rightarrow \frac{\partial M_i}{\partial w} = y_i x_i$$



# Линейные модели: построение


## Градиентный спуск (GD)

$$\nabla_w \tilde{Q} = \sum_{i=1}^l \nabla L(M_i) = \sum_{i=1}^l L'(M_i) \frac{\partial M_i}{\partial w}$$

$$x_{k+1} = x_k - \gamma_k \nabla F(x_k)$$

$$M_i = y_i \langle w, x_i \rangle \Rightarrow \frac{\partial M_i}{\partial w} = y_i x_i$$

$$\nabla \tilde{Q} = \sum_{i=1}^l y_i x_i L'(M_i)$$



# Линейные модели: построение


## Градиентный спуск (GD)

$$\nabla_w \tilde{Q} = \sum_{i=1}^l \nabla L(M_i) = \sum_{i=1}^l L'(M_i) \frac{\partial M_i}{\partial w}$$

$$x_{k+1} = x_k - \gamma_k \nabla F(x_k)$$

$$M_i = y_i \langle w, x_i \rangle \Rightarrow \frac{\partial M_i}{\partial w} = y_i x_i$$

$$\nabla \tilde{Q} = \sum_{i=1}^l y_i x_i L'(M_i)$$



$$w_{k+1} = w_k - \gamma_k \sum_{i=1}^l y_i x_i L'(M_i)$$

Линейные  
модели:  
построение

# Стохастический градиент (SGD)

$$w_{k+1} = w_k - \gamma_k \sum_{i=1}^l y_i x_i L'(M_i)$$

$$w_{k+1} = w_k - \gamma_k y_i x_i L'(M_i)$$

$x_i$  — случайный элемент обучающей выборки



# Линейные модели: построение

## To take away:

Линейные модели имеют ряд преимуществ:

- Простота реализации
- Скорость работы
- Хорошее качество, когда много признаков
- Приемлемое качество, когда мало данных

### Особенности применения

- Модель может оказаться слишком простой для задачи
- Требуется бороться с переобучением:  
регуляризация, масштабирование признаков

# Машинное обучение: линейные модели классификации и регрессии

Спасибо!  
Эмили Драль